КОГДА УТОЧНЕНИЕ ПОМОГАЕТ

Разведочный анализ данных

Чекпойнт 2 · 27 октября 2026

Губарева Анна Владимировна
Магистратура «Искусственный интеллект», 1 курс
Руководитель: Макаров Илья Андреевич
Непосредственный куратор: Насонов Илья

Исследуем, как выбирать вопрос, который помогает принять лучшее решение, если пользователь отвечает точно, неоднозначно или «не знаю».

Что готово к чекпойнту

Критерий README	Результат
Первая версия данных	812 каталогов; 6496 связанных строк задача–вопрос; JSONL и словарь полей
Полные и неполные ответы	Три формальные категории и явные вероятности симулятора
Основные наблюдения	Проверки данных и предварительное сравнение шести подходов
Графики	Пять рисунков: состав, распределения, ответы, полезность и выбор вопросов

Основной результат

Простая обученная поправка почти достигает точного ориентира: она выбирает лучший вопрос в 84 из 90 проверочных задач. Усложнение оценивателя пока не даёт убедительного выигрыша.

Граница результата: один синтетический механизм ответов, математический исполнитель, без новых вызовов LLM и без исследования людей. Основная гипотеза о переносе раздельного оценивателя ещё не подтверждена.

1. Данные и единица наблюдения

Система выбирает один из трёх рейсов. Рейс описан восемью числовыми признаками; предпочтения пользователя представлены коэффициентами полезности. Каждый из восьми вопросов уточняет знак одного коэффициента.

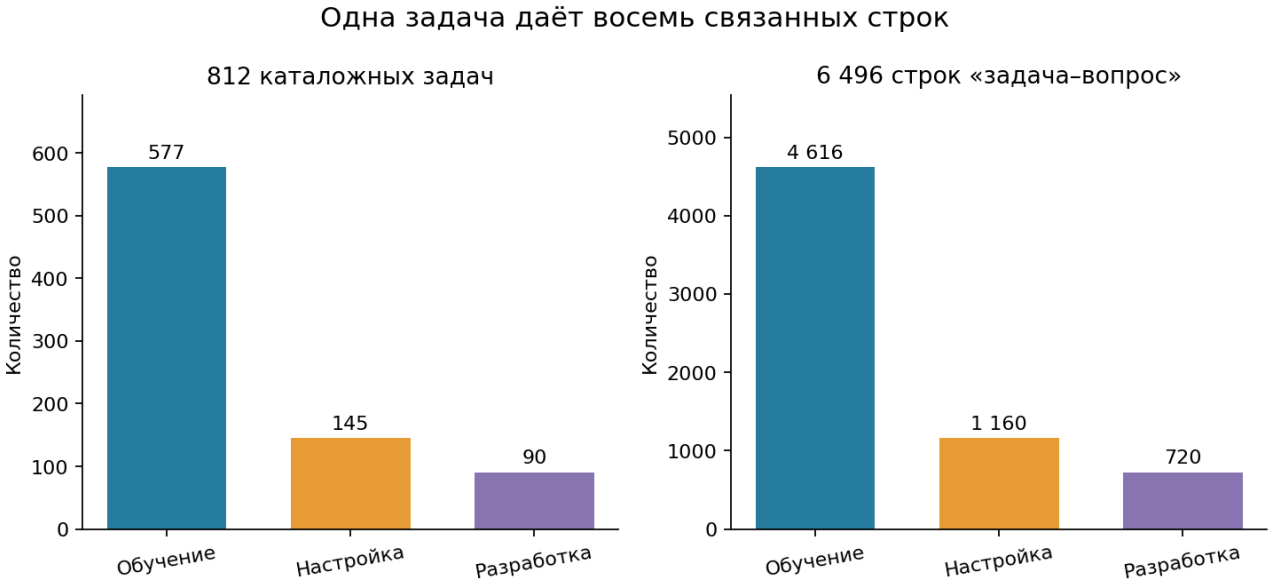


Рис. 1. Разбиение E002. Восемь строк одной задачи связаны между собой и должны оставаться в одной выборке.

Происхождение

Каталоги и профили взяты из открытого репозитория VOI_communication (flight_rec), по одному последнему каталогу из записи. Ответы пользователей и метки пользы созданы нашим симулятором; это не наблюдения реальных диалогов.

Commit: 27466a7832d5aafff82017a659e08942e18b01ae. Контрольные суммы входов и выходов сохранены в data/manifest.json.

В первой передаваемой версии - производные признаки, вероятности и симуляционные метки. Сырые внешние каталоги и профили не перепубликуются: отдельный файл лицензии в проверенной версии исходника не найден.

Всем методам известен один prior по 577 fit-записям предпочтений (576 уникальных векторов). Повторённый профиль сохраняет исходный вес. Истинные профили eval-пользователей при расчёте меток не используются.

2. Качество и распределения

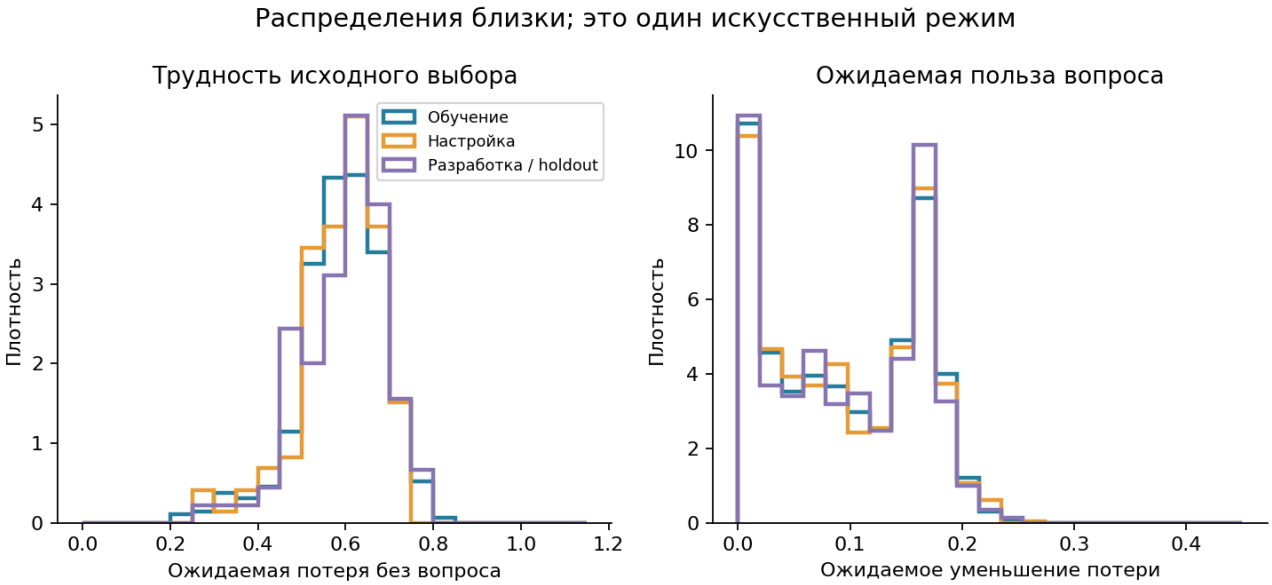


Рис. 2. Слева - исходная трудность задачи без уточнения; справа - ожидаемая полезность отдельных вопросов. Единицы численной полезности, не проценты.

Что проверено

Полнота полей, NaN/Inf, уникальность ключа (задача, вопрос), наличие восьми вопросов, нормировка вероятностей и границы меток. Пересчёт сохранённой модели и её результатов входит в проверку воспроизводимости.

Каталоги между выборками не пересекаются, включая перестановки рейсов. Разделение строк случайным образом недопустимо: оно перенесло бы части одной задачи одновременно в обучение и проверку.

Ограничения независимости

Fit и validation разделены по профилям. В исходном eval есть один вектор предпочтений, совпадающий с fit, при другом каталоге. Это не утечка eval-профиля в метки, но нельзя заявлять проверку только на новых пользователях.

90 проверочных каталогов уже многократно использованы в разработке. Они называются development holdout и не заменяют будущий нетронутый test. Похожесть распределений не является доказательством переноса в другую среду.

3. Как устроены ответы

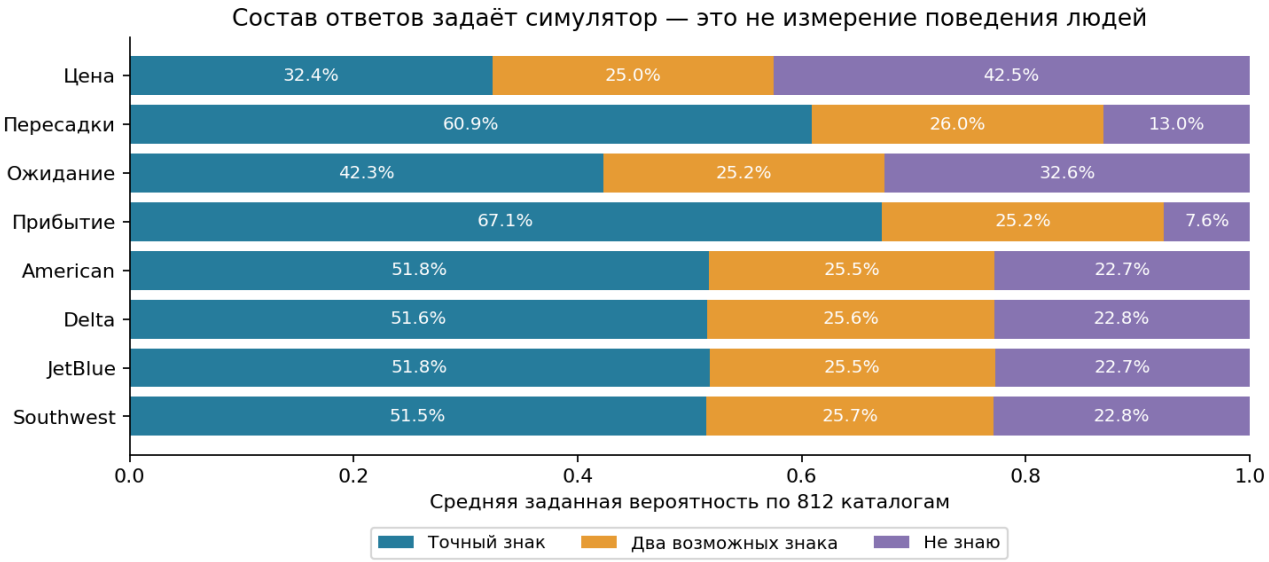


Рис. 3. Средние назначенные вероятности по 812 каталогам. Это свойства симулятора, а не измеренные частоты человеческих ответов.

Ответ	Информация о предпочтении
Точный	Один знак: отрицательный, ноль или положительный
Неоднозначный	Два возможных знака; истинный всегда входит в пару
«Не знаю»	В E002 не изменяет распределение предпочтений

Вероятности зависят от вопроса и размаха признака в каталоге: e = base[q] − 0.15 × span; b = 0.2 + 0.1 × span; вероятность «не знаю» = 1 − e − b. Частичная пара выбирается равновероятно из двух подходящих.

При фиксированных вопросе и каталоге вид ответа в E002 не зависит от скрытого профиля. Точный ответ раскрывает только один признак, а не всю цель. Текстовое понимание и ошибочные ответы пока не моделируются.

4. Что теряется при неполном ответе

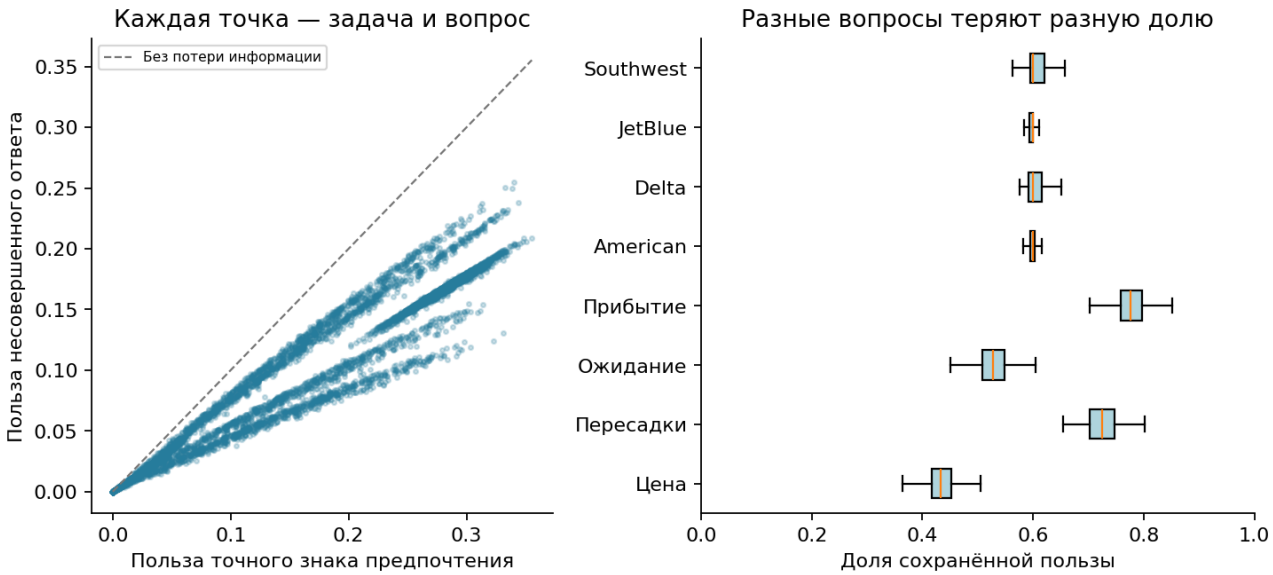


Рис. 4. 6496 пар задача–вопрос. Точный знак - верхний ориентир только для данного класса каналов, где ответ является его случайным огрублением.

Что показывает анализ

Несовершенный ответ сохраняет разную долю пользы для разных вопросов. Поэтому выбор в предположении точного ответа может отличаться от выбора с учётом частичных ответов и отказов.

Вместе с тем структура этой задачи проста. Из-за независимости типа ответа от профиля и различимости трёх ветвей ожидаемая ценность точно равна:

V = e × V_exact + b × V_partial.

Независимый пересчёт всех 6496 строк подтвердил это равенство с расхождением менее 10^{-15}. Ветвь «не знаю» здесь даёт нулевую выгоду. Это помогает объяснить успех простой поправки на тип вопроса.

Формула не переносится автоматически на другой механизм: если отказ зависит от скрытого предпочтения, сам факт отказа может сообщать информацию. Для реального агента неправильное понимание ответа также может ухудшать решение.

5. Первые результаты

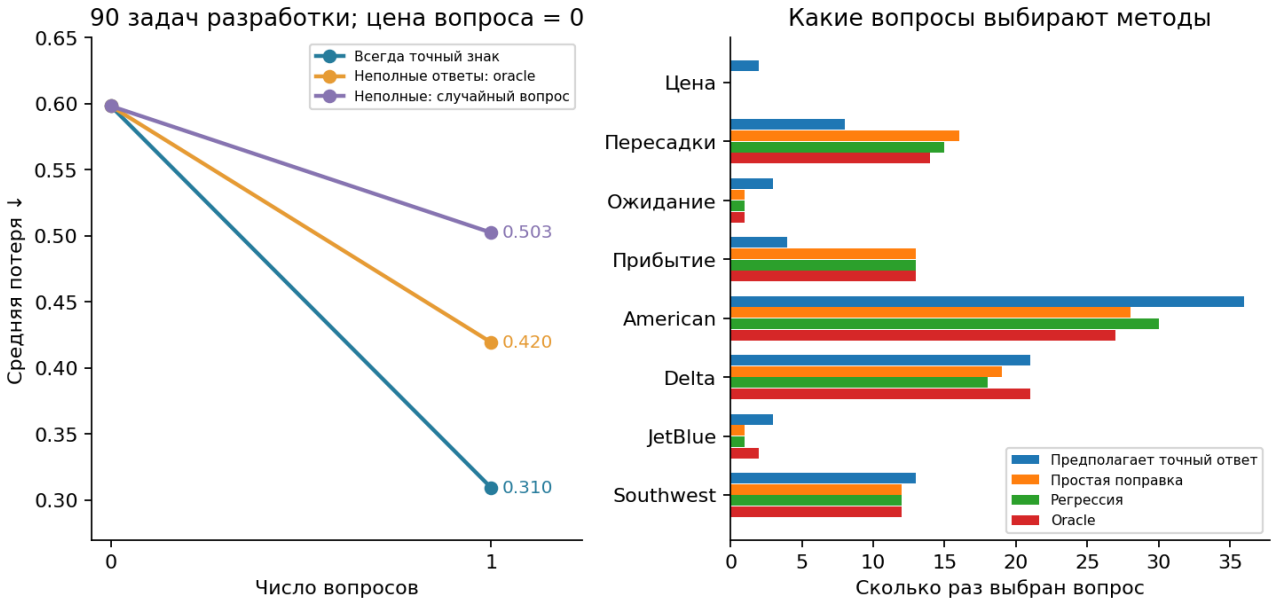


Рис. 5. 90 development-задач. Слева два разных канала ответов; соединение точек 0 и 1 не является проверкой нескольких последовательных вопросов. Справа выбор вопроса при неполном канале.

Подход	Средняя потеря ↓
Без уточнения	0.598205
Случайный вопрос	0.502505
Выбор в предположении точного ответа	0.424751
Простая обученная поправка	0.419669
Ridge-оцениватель	0.419635
Точный ориентир для неполного канала	0.419503

Потеря - полезность лучшего рейса для скрытого профиля минус полезность выбранного, усреднённая по prior и ответам. Цена вопроса в основной таблице равна нулю. Шкала не нормирована в [0,1].

Ridge выигрывает у простой поправки лишь 0.00003417; парный 95% bootstrap интервал разности [−0.00010251; 0]. Это условная оценка по каталогам при одной фиксированной популяции и одном обучении.

6. Выводы, ограничения и повторение

Главный вывод

В данном симуляторе учёт несовершенного ответа помогает относительно ожидания точного ответа. Однако простая поправка почти исчерпывает выигрыш: средний разрыв до точного ориентира 0.00016545. Оснований увеличивать модель по этим результатам нет.

Что ещё не выполнено по исходному плану

Рейсы - промежуточная диагностическая замена устройств и учебных курсов. Один вопрос вместо двух, 90 development-каталогов вместо независимого пилота на 150–200, известный prior вместо его обучения из текста. Метки E002 точные симуляционные; это сильная привилегированная разметка.

Основное сравнение прямого и раздельного оценивания при переносе, полный набор SAGE/IG baselines, независимая агентная среда и утверждения о реальных людях этим отчётом не закрыты. Новые исследования от 27 октября вынесены в отдельные документы.

Как проверить результат

Пакет содержит REPORT.md, DATA_CARD.md, REPRODUCE.md, data/question_values_v1.jsonl, analysis.json, пять рисунков PNG/SVG, исходные аналитические артефакты E002 и код сборки. Внешние исходные каталоги и модели не включены.

Из корня распакованного архива: **python3 experiments/checkpoint2_eda.py**. Нужны Python, NumPy и Matplotlib. Сборка работает по включённым артефактам, без API и без скачивания языковой модели. Расширенный аудит исходников описан отдельно.

Источники

1. README проекта: ожидаемые результаты чекпойнта 2.
2. VOI_communication, закреплённая версия исходных данных.
3. Протоколы и отчёты E002/E004 в исследовательском приложении пакета.

Материалы подготовлены по указанным критериям README. Загрузка в учебную систему не выполнялась.